IMG & PDF OCR WEBUI

技術手冊

中央大學 MIAT 實驗室

鄧祺文

目錄

系統設計架構

- ✧ 功能需求：讀取 IMG 和 PDF 文件，將其中的內容透過光學字元辨識（OCR, Optical Character Recognition）進行擷取，最後輸出成可運用的文字檔案格式。
- ✧ 開發環境：功能 Python，後端 Flask，前端 HTML 及 Bootstrap
- ✧ 部屬環境：Docker Container with Ubuntu 20.04, CUDA v11.7.1 and cuDNN v8
- ✧ 專案代碼開源地址：

  https://github.com/toby0622/IMG-Optical-Character-Recognition-Tool
- ✧ Docker 專案自動化部屬：

  https://github.com/toby0622/IMG-Optical-Character-Recognition-Tool-Docker
- ✧ IDEF0 和 Grafcet

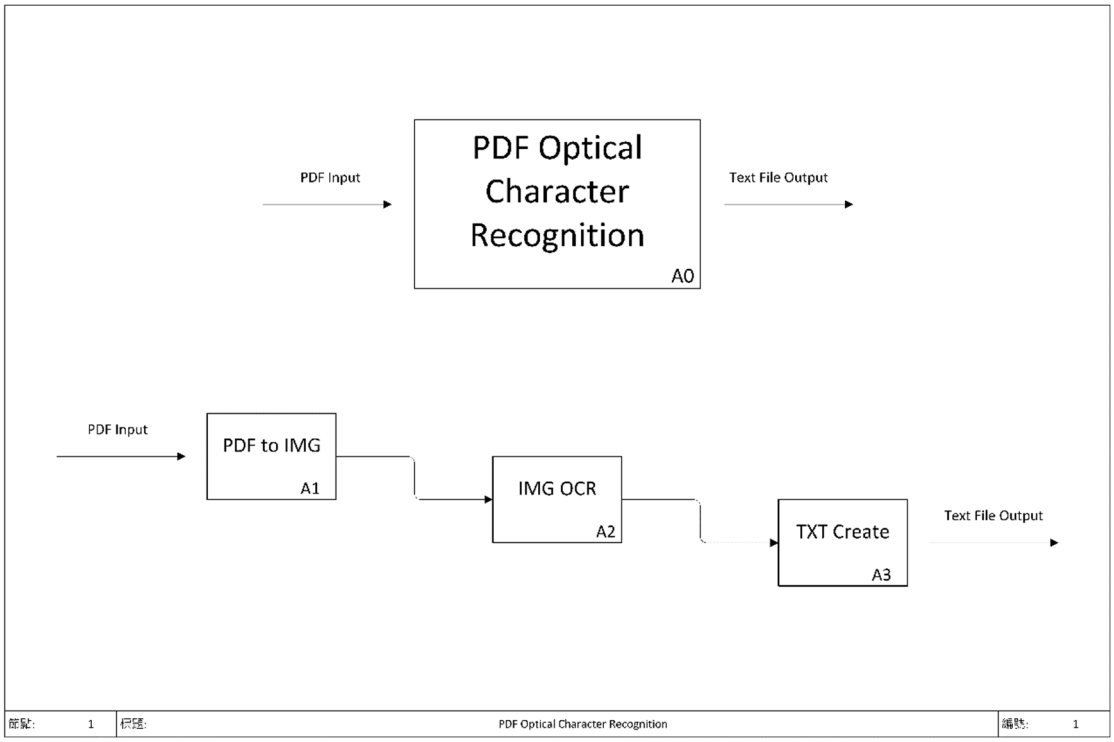

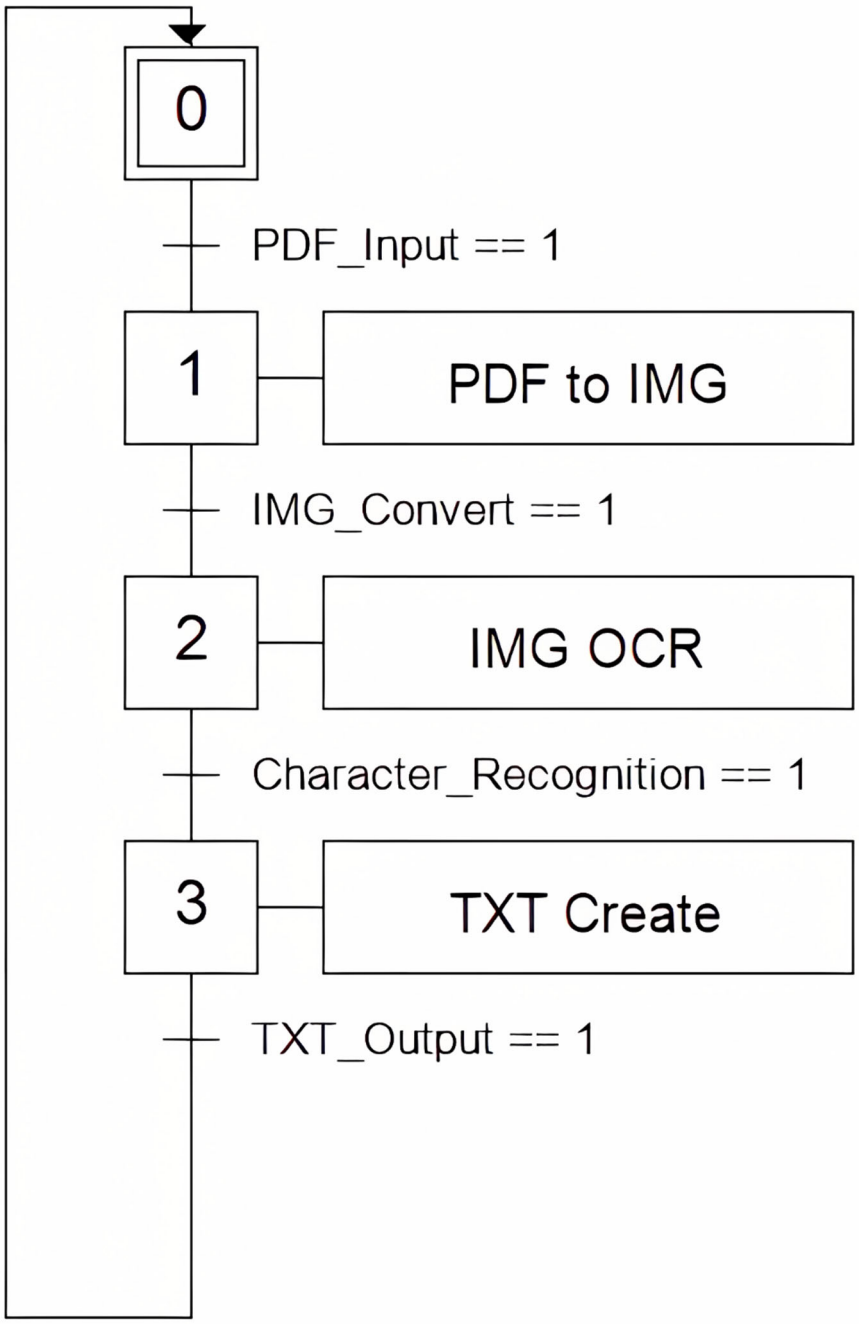
0
PDF_Input == 1
1
PDF to IMG
IMG_Convert == 1
2
IMG OCR
Character_Recognition == 1
3
TXT Create
TXT_Output == 1

辨識模型

✧ 論文主題：

SVTR: Scene Text Recognition with a Single Visual Model

✧ 論文地址：

https://arxiv.org/abs/2205.00159

✧ 模型代碼開源地址：

https://github.com/PaddlePaddle/PaddleOCR

✧ 技術簡介：

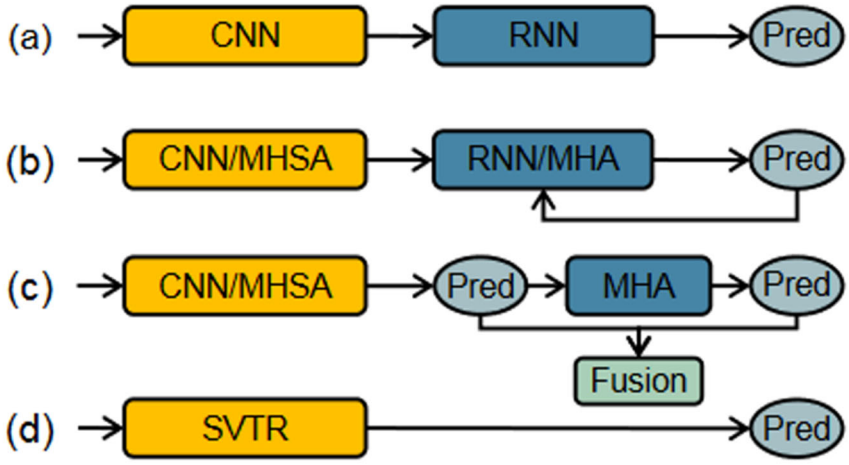

Figure 1: (a) CNN-RNN based models. (b) Encoder-Decoder models. MHSA and MHA denote multi-head self-attention and multi-head attention, respectively. (c) Vision-Language models. (d) Our SVTR, which recognizes scene text with a single visual model and enjoys efficient, accurate and cross-lingual versatile.

場景文字識別可以看作是一個從圖像映射到序列的任務。大多數的識別算法通常由兩個模塊構成，分別包含用於特征提取的視覺模塊，以及用於文本輸出的序列模塊。比如早期基於 CNN-RNN 的 CRNN，和現在一些基於注意力機制，進行自回歸式解碼

的算法，如上圖（圖一）所示。但是這樣設計出之雙階段算法的推理速度往往較慢，難以滿足工業應用的需求。因此該論文從推理速度和模型性能的雙重角度出發，提出了只由 Transformer 構成的純視覺模塊網絡 SVTR，在消費級顯示卡上達到了毫秒級的推理速度，並且參數量僅有 6 M。

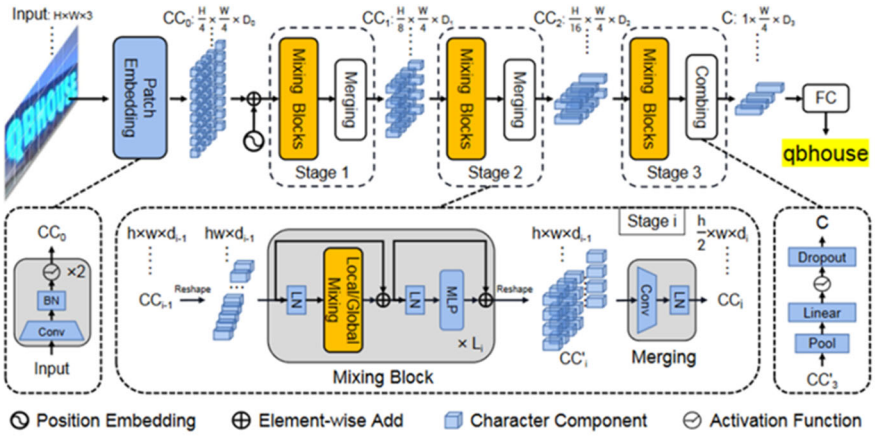

Figure 2: Overall architecture of the proposed SVTR. It is a three-stage height progressively decreased network. In each stage, a series of mixing blocks are carried out and followed by a merging or combining operation. At last, the recognition is conducted by a linear prediction.

上圖（圖二）為該論文所提出模塊網路 SVTR 的整體結構，采用類似於 SwinTransformer 的視覺模型和一個全連接層以及 CTC 解碼器進行文本序列預測。

首先和 ViT 類似，將輸入尺寸為 $H \times W \times 3$ 圖像按照 Patch 進行劃分，得到 $\frac{H}{4} \times \frac{W}{4} \times D_0$ Embeddings。本文采用的 Patch Embedding 操作和 ViT 中的有些許差異，其由兩層步距為 2，卷積核大小為卷積層 3×3，以及 BN 層構成。這樣不同的 Patch 之

間是存在著重疊的，如下圖（圖三）所示。經過 Patch Embedding 後的序列將經過一系列的 Stage，每一個 Stage 都由一系列的 Mixing Block 和 Merging Layer 構成。

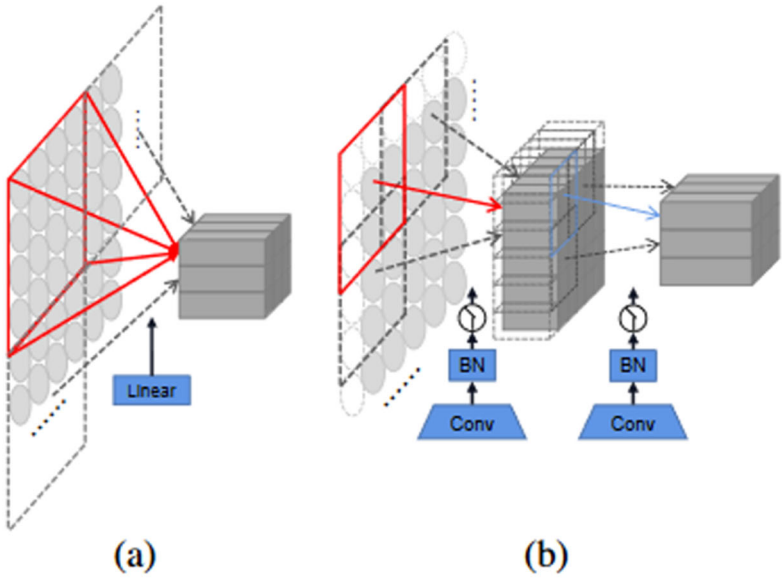

Figure 3: (a) The linear projection in ViT[Dosovitskiy *et al.*, 2021]. (b) Our progressive overlapping patch embedding.

作者認為文本識別需要兩種特征。第一種是局部特征，如筆畫特征。它編碼了字符的不同部分之間的形態特征和相關性。第二種是字符間的依賴性，如不同字符之間或文字與非文字成分之間的相關性。因此，作者設計了兩個混合模塊，即 Global Mixing 和 Local Mixing，通過使用不同大小感受的自注意層來實現。如下圖所示。Global Mixing 層本質上就是一個 Transformer Block，由一個多頭自注意層，一個 Layer Norm 層，以及一個 MLP 層構

成。通過自注意力機制的全局建模特性來進行全局字符建模。Local Mixing 則是采用了帶窗的自注意層，窗大小設置為了 7×11。

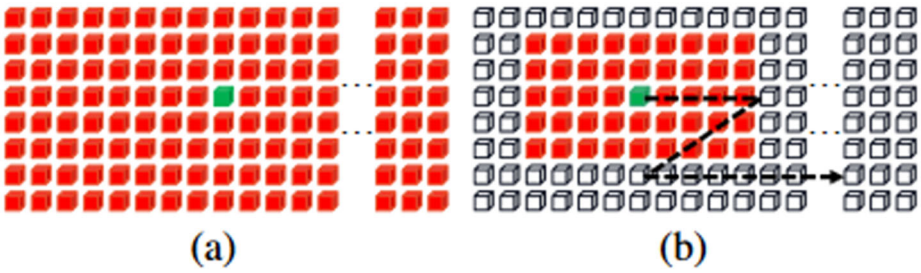

Figure 4: Illustration of (a) global mixing and (b) local mixing.

Merging 層扮演著將輸入序列進行下采樣的角色。其由高度方向步距為 2，寬度方向步距為 1，卷積核大小為 3×3 的卷積層構成。將輸入序列的尺寸由 $h \times w \times d_{i-1}$ 縮小為 $\frac{h}{2} \times w \times d_{i-1}$。同時每經過一次 Merging 層，序列的 Channel 維度也會增大，從而彌補在高度上的信息損失。

網頁功能入口

✧ 功能入口

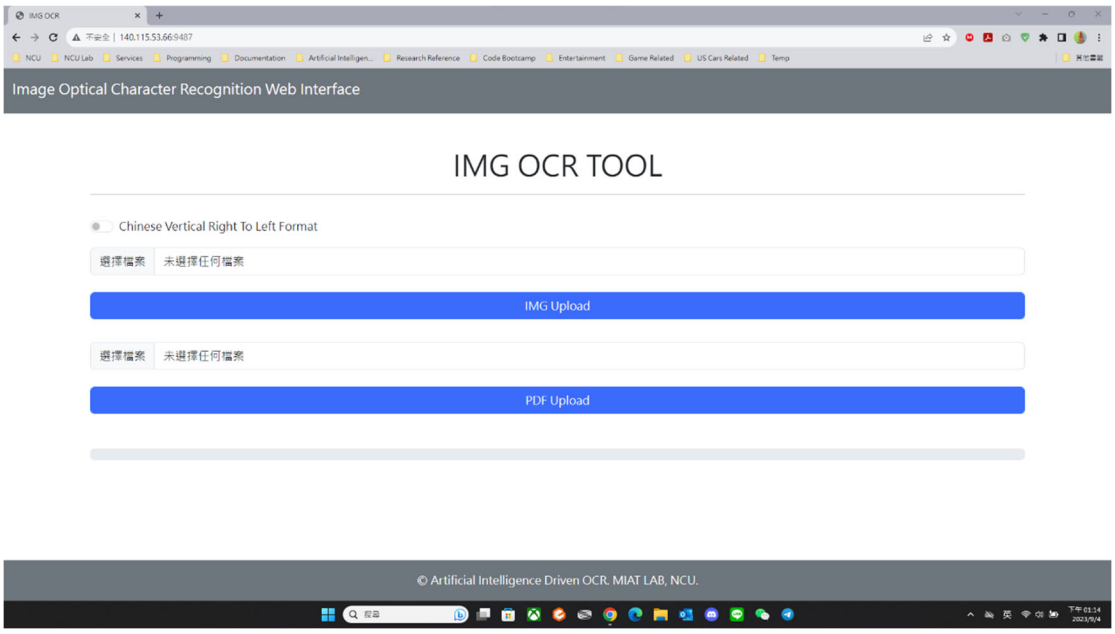

✧ 上半部選擇框：支持 JPG、JPEG、PNG

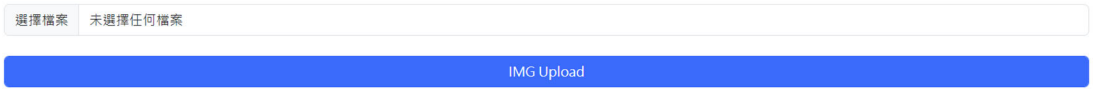

✧ 下半部選擇框：支持 PDF

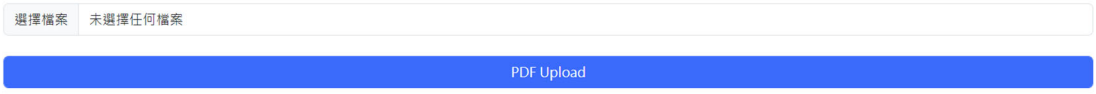

✧ 圖像特殊排序：中文直式由右至左（預設標準為由上至下）

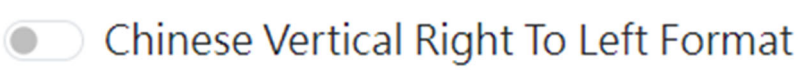

✧ 成功讀取資料後，可於下方看見處理進度條

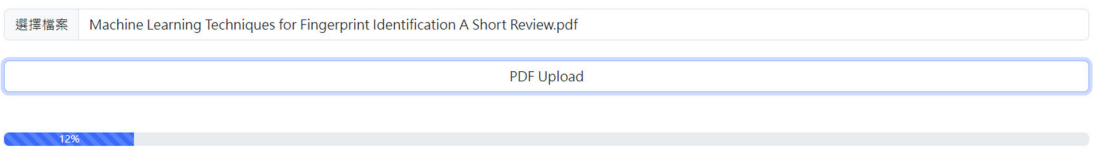

網頁結果輸出

✧ 結果輸出頁面：上半部

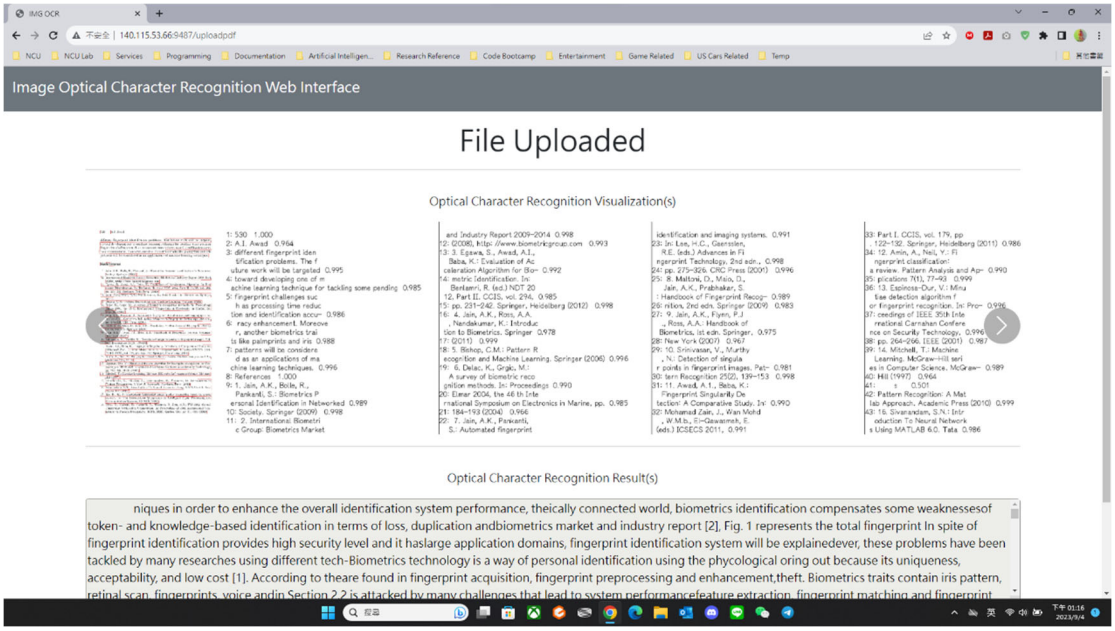

✧ 結果輸出頁面：下半部

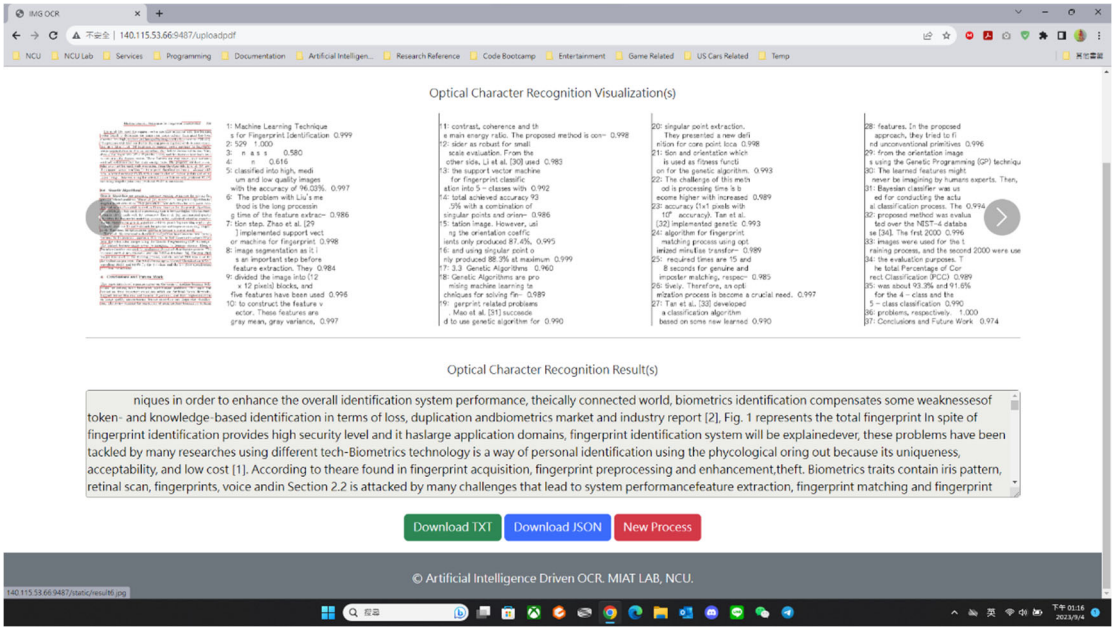

✧ 輸出視覺化：包含辨識框及輸出結果展示，左右按鍵可變換當前展示頁面

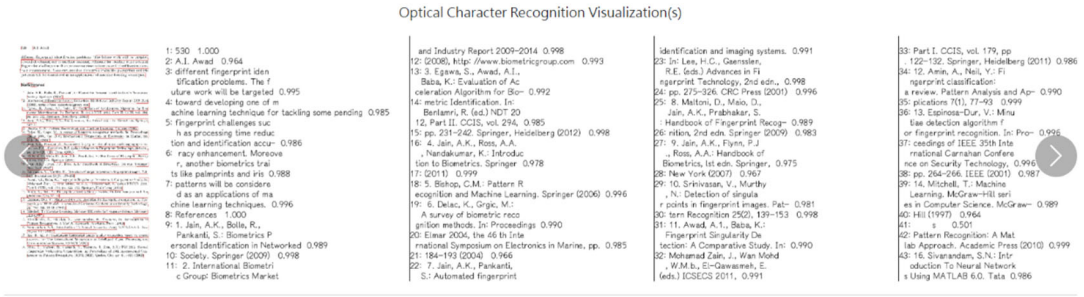

✧ 直接點擊圖片進入相簿模式，可以對圖片進行放大

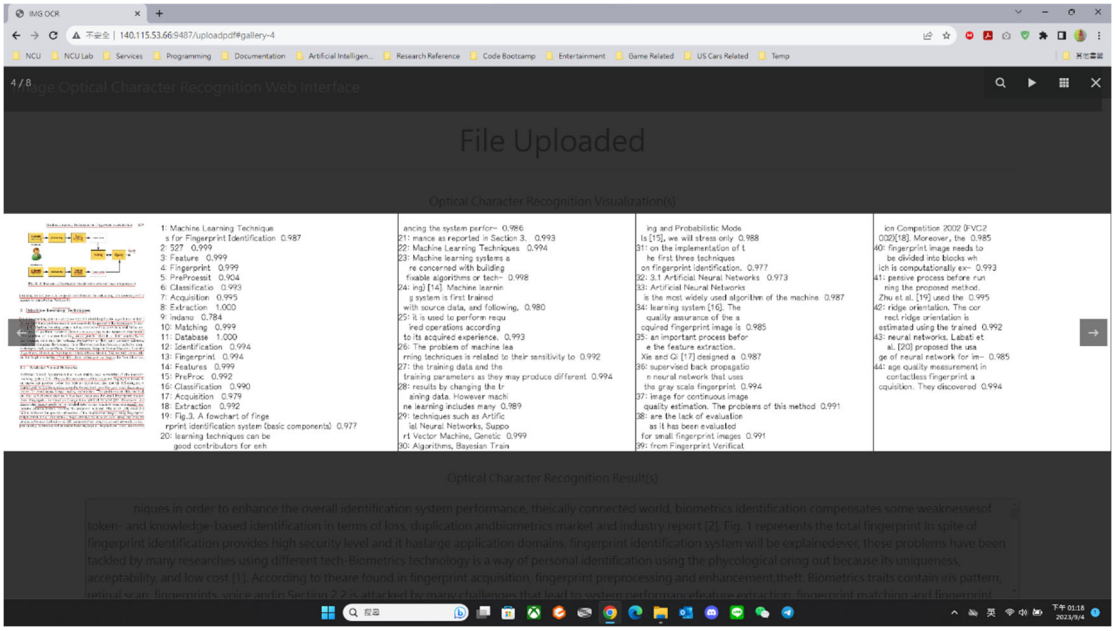

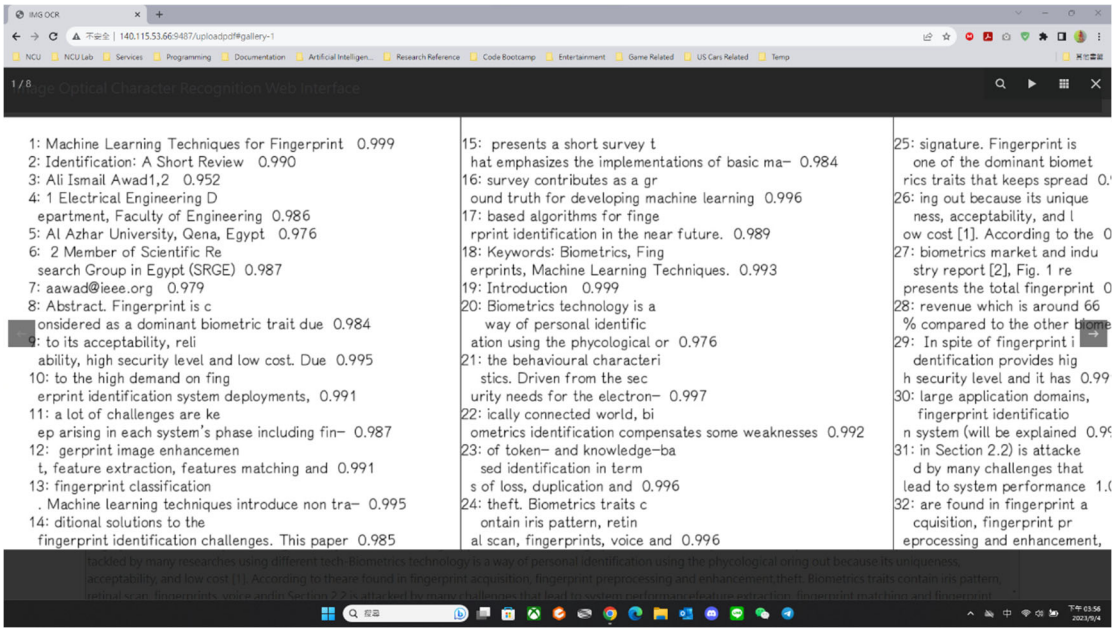

✧ 完整文字輸出：包含所有頁面辨識出之完整文章

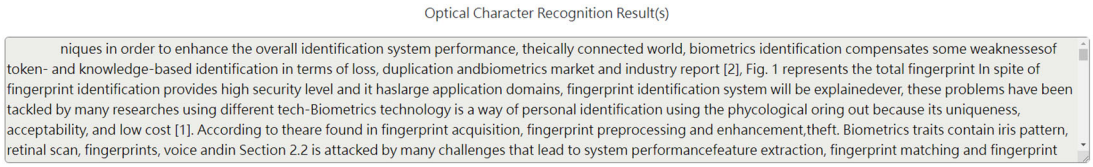

✧ 文章打包功能：包含 TXT 文字檔下載、API 串接用 JSON 檔案下載，以及重新開始新一輪識別